

# N1

November 18, 2025

## 1 1 Conocimientos básicos sobre Electroencefalografía Superficial.

**Materias relacionadas:** Algoritmos Computacionales, Morfológico II, Instrumentación Biomédica, Física del Cuerpo Humano, Electrofisiología y Temas Selectos de Biofísica.

**Objetivo:** Conocer las bases fisiológicas de la técnica del electroencefalograma y establecer las bases para el posterior desarrollo de los notebooks.

### 1.1 1.1 EEG y sus bases fisiológicas.

El EEG mide la actividad eléctrica de las células en la corteza cerebral (Olejniczak, 2006). Es una representación de la diferencia de potencial entre dos regiones corticales cuando se trata de una adquisición bipolar y se grafica con respecto del tiempo (Olejniczak, 2006). En cambio con una derivación monopolar se registra la diferencia de potencial entre un electrodo activo colocado en el cuero cabelludo y un electrodo de referencia colocado en un punto neutro como el lóbulo de la oreja o el mastoides (Ramos-Argüelles et al., 2009).

Para conocer la señal producida por los potenciales cerebrales es importante identificar el generador y los campos eléctricos que se generan (Olejniczak, 2006). Las señales eléctricas se crean cuando las cargas eléctricas se mueven por el sistema nervioso central y para mantenerlas es necesaria la existencia de gradientes iónicos (Olejniczak, 2006; Hari & Puce, 2017).


- 1. A nivel celular:** La actividad que se capta en un EEG proviene principalmente de las neuronas que son células del sistema nervioso que tienen interconexión por medio de impulsos eléctricos (Hari & Puce, 2017). Se genera una despolarización, que es un cambio en el potencial eléctrico de una célula excitante o grupo de células excitables donde el interior de la célula se vuelve menos negativo en relación con el exterior de la membrana (Hari & Puce, 2017). El potencial de membrana en reposo de una neurona se da porque hay una salida de iones K<sup>+</sup> que mantienen el equilibrio alrededor de -75mV (Hari & Puce, 2017). Cuando hay una depolarización hay un flujo de iones Na<sup>+</sup> que excede el estado electroquímico normal de reposo (Hari & Puce, 2017). La apertura del canal en la membrana sucede gracias a un mecanismo dependiente de voltaje y el cierre depende del tiempo (Hari & Puce, 2017). La conducción a porciones vecinas a las membranas de las células nerviosas resultan en un potencial de acción (Hari & Puce, 2017).

Para que esta actividad sea detectada por el electrodo se necesita la suma de actividades de un gran número de neuronas, ya que no podemos medir los voltajes individualmente con este método (Hari & Puce, 2017). La señal que se obtiene en los electrodos se encuentra en el orden de microvolts, por lo que necesita ser amplificada (Olejniczak, 2006).

Los potenciales sinápticos son la fuente más importante para el registro extracelular (Olejniczak, 2006). Los potenciales excitatorios postsinápticos (EPPs) fluyen hacia dentro de otras partes de la célula gracias a iones de sodio o de calcio (Hari & Puce, 2017). Los potenciales inhibitorios postsinápticos (IPPs) fluyen hacia afuera en dirección opuesta gracias a iones de cloro o de potasio (Hari & Puce, 2017). La suma de estos potenciales tienen una duración más larga que los potenciales de acción y dan las formas de onda característica del EEG (Olejniczak, 2006).

La conducción por volumen caracteriza el proceso de flujo de corriente entre el generador y el electrodo de registro (Olejniczak, 2006). La corteza cerebral es la principal fuente (Olejniczak, 2006). Las células piramidales suelen ser las que más aportan a los potenciales registrados por la forma en que están orientadas (Olejniczak, 2006). Un volumen suficientemente grande para que pueda ser registrado por el electrodo necesita un área de entre 6 y 10 cm<sup>2</sup> (Olejniczak, 2006). Se necesitan estas áreas porque la piel, el cabello y el cráneo tienen un efecto atenuador (Olejniczak, 2006).

- Imagen de la cabeza con electrodos \*



<https://www.emotiv.com/blogs/how-to/understanding-the-10-20-system-of-eeg-electrode-placement?srsltid=AfmBOoqYtCG8pcBAz4NJAsPssyFGJ9LYm28Dbflff8k1w-7JGDIBrJ86>

## 1.2 1.2 Características de la señal

La señal de EEG presenta potenciales del orden del 10 V, por lo que supone un reto medir la actividad con dispositivos que suelen medir en el orden de voltios, por lo que el sistema debe amplificar alrededor de un millón de veces la señal (Ramos-Argüelles et al., 2009). Si se piensa en cómo se registraría eso, se necesita un sensor que reciba la información proveniente de las señales eléctricas del cerebro, este sensor es el electrodo (Ramos-Argüelles et al., 2009). La señal obtenida va de los 0 a los 30 Hz (Hari & Puce, 2017).

Posteriormente, debe existir un dispositivo que registre la señal que está recibiendo el electrodo, en este caso sería el circuito básico del EEG, que contiene diversos circuitos de amplificación, para recibir la señal (Ramos-Argüelles et al., 2009). Una vez recibida la señal, debe obtenerse la gráfica (LaVaque, 1999).

En los instrumentos modernos de EEG, se lleva a cabo una conversión analógica-digital (Saptono et al., 2016). De esta forma se puede procesar la señal en la computadora, y cuando se quiere limpiar la señal pueden aplicarse distintos algoritmos y filtros para mejorar la resolución de la señal y eliminar artefactos (Saptono et al., 2016).

Las características generales de los electrodos para EEG deben ser: pequeños, de metales no reactivos, con forma de copa colocados sobre el cuero cabelludo y con un pegamento conductor (para evitar señales no deseadas) (Saptono et al., 2016). Entre los metales para su fabricación están: oro, plata, plata-cloruro de plata y platino, debe procurarse siempre el contacto óptimo para tener poca impedancia (Saptono et al., 2016). Se colocan en una gorra, diadema o directamente en electrodos que se ponen al paciente (Saptono et al., 2016).

En las siguientes figuras se observa la gorra con los electrodos y la posición de estos.

Tipo de onda	Rango de frecuencia	Localización	En estado fisiológico
Delta	1-4 Hz	En adolescentes y niños pequeños en la parte posterior de la cabeza.	Aparece durante el ritmo normal de sueño, y en uno de cada tres adultos puede apreciarse cuando se está despierto con los ojos abiertos
Theta	4-8 Hz	Puede estar ausente, pero si se encuentra, está en la línea media y derivaciones temporales.	Marcada en niños pequeños. Somnolencia en adultos
Alfa	8-13 Hz	Regiones frontocentrales pero también distribución amplia	Con los ojos cerrados, mientras se está relajado

Tipo de onda	Rango de frecuencia	Localización	En estado fisiológico
Beta	13-30 Hz	Regiones posteriores de la cabeza	Con los ojos abiertos, mientras se está relajado. La actividad es mayor en un lado dominante
Gamma	>30 Hz	Distribución amplia pero principalmente centrales y temporales	Cognición

### 1.3 1.3 Metodología para obtener una señal EEG

En esta sección se describe la metodología empleada para la adquisición de las señales de electroencefalografía (EEG) utilizadas a lo largo de este cuaderno.

El objetivo general fue registrar la actividad eléctrica cerebral en estado de reposo con ojos abiertos y cerrados, bajo condiciones controladas, empleando un sistema de adquisición no invasivo.

#### 1.3.1 1.3.1 Protocolo experimental

Los datos utilizados en este notebook para la visualización de las señales se obtuvieron del protocolo experimental “**Electroencefalografía superficial en estado de reposo con ojos cerrados y ojos abiertos**”, desarrollado por **Gabriela González y Saúl Saldaña** dentro del *Manual Digital de Prácticas Teóricas y Experimentales para el Estudio de Electrofisiología* (2024).

Durante la adquisición, se registró una señal EEG continua durante **3 minutos** utilizando el sistema **Emotiv EPOC+** (EMOTIV, 2016).

El participante permaneció en reposo, sentado cómodamente y con mínima movilidad facial o corporal. Se le pidió alternar períodos de apertura y cierre ocular según la siguiente secuencia:

Etapa	Condición	Duración (s)	Intervalo (s)
a	Ojos cerrados (adaptación)	30	0–30
b	Ojos cerrados	30	30–60
c	Ojos abiertos	30	60–90
d	Ojos cerrados	15	90–105
e	Ojos abiertos	15	105–120
f	Ojos cerrados	15	120–135
g	Ojos abiertos	15	135–150
h	Ojos cerrados (final del registro)	30	150–180

Este diseño experimental se realizó con la finalidad de **observar la aparición y modulación de las ondas alfa (8–13 Hz)** durante el estado de reposo con ojos cerrados, en comparación con los períodos de ojos abiertos.

Para consultar la versión completa del protocolo y los procedimientos de registro, se puede acceder al documento público disponible en el siguiente enlace:

[Protocolo completo en GitHub — Manual Digital de Prácticas Teóricas y Experimentales para el Estudio de Electrofisiología](#)

### **1.3.2 1.3.2 Equipo utilizado: EMOTIV EPOC+**

Para la adquisición de las señales EEG se utilizó el sistema **EMOTIV EPOC+**, un dispositivo inalámbrico de **14 canales activos** más **2 electrodos de referencia (CMS/DRL)**.

Este sistema emplea electrodos secos basados en polímeros conductivos, diseñados para la adquisición no invasiva de potenciales eléctricos cerebrales.

#### **Características técnicas principales:**

- **Canales de adquisición:** 14 canales + 2 referencias (CMS/DRL)
- **Frecuencia de muestreo:** 128 Hz por canal
- **Resolución:** 16 bits
- **Ancho de banda:** 0.2–45 Hz
- **Conectividad:** Inalámbrica (2.4 GHz)
- **Autonomía:** Hasta 12 horas de uso continuo
- **Tipo de electrodos:** Secos reutilizables (polímero conductor)
- **Configuración de adquisición:** Monopolar, donde cada electrodo activo mide el potencial con respecto a una referencia común.

Esta configuración permite obtener la actividad eléctrica absoluta de cada ubicación de electrodo en relación con la referencia, facilitando la comparación entre regiones corticales.

#### **Esquema de colocación de electrodos:**

*Figura 1.* Distribución de los electrodos en el sistema internacional 10–20 (configuración Emotiv EPOC+).

*(Inserta aquí una imagen ilustrativa del esquema de cabeza con electrodos, o una referencia visual a tu archivo de figuras).*

#### **Fotografía del equipo:**



Fuente: [EMOTIV — EPOC X Product Page](#)

**Referencia técnica:**

EMOTIV. (2016). *EPOC+ EEG Headset: 14 Channel Wireless EEG System* [Dispositivo de registro de EEG]. EMOTIV Inc.

Recuperado de <https://www.emotiv.com>

#### 1.4 1.4 Preparando el entorno de Python para trabajar con los datos experimentales

Teniendo el contexto de la fisiología de las señales podemos hacer un análisis sencillo en el que observemos cómo evoluciona temporalmente el voltaje de cada una. Debemos tomar en cuenta que estamos graficando valores de voltaje que corresponden a un valor en el tiempo, ambas son variables numéricas.

A continuación se proveen enlaces para descargar las bibliotecas necesarias para abrir los datos, se trata de paquetes que incluyen funciones específicas para realizar cálculos, graficar, transformar los tipos de datos e incluso trabajar con formatos específicos de señales. Es importante que cuentes con ellas debido a que las usaremos a lo largo de los siete notebooks. Si ya cuentas con ellas omite esta parte; si no, ingresa al link que contenga la biblioteca que te hace falta.

- **Pandas:** Es una biblioteca que se desarrolló en 2008 (Rajagopalan, 2021). Se utiliza para el análisis econométrico de series de tiempo. Entre las características que resaltan están:

1. Provee indexación y etiquetado de datos
2. Permite leer archivos de distintas fuentes: Excel, CSV (del que hablaremos en el notebook 3) y JSON.
3. Visualización de datos reforzada en matplotlib
4. Comunicación con otras bibliotecas como matplotlib, scipy y numpy
5. Facilita la limpieza de datos.

Las instrucciones para descargarla podemos encontrarlas en el siguiente enlace: [https://pandas.pydata.org/docs/getting\\_started/install.html](https://pandas.pydata.org/docs/getting_started/install.html)

- **Numpy:** Es una biblioteca de Python que se utiliza para cómputo matemático y procesar arreglos o colecciones. La configuración por default de Python procesa estructuras de datos de una dimensión. Los arreglos se vuelven una estructura fundamental pues pueden remodelar objetos y utilizan principios de vectorización de forma que si se aplica una operación a este objeto afecta a todos sus elementos (Rajagopalan, 2021). Las colecciones serán fundamentales en el desarrollo de los notebooks pues nos permiten realizar cálculos, operaciones y obtener gráficas.

Las instrucciones para descargar NumPy podemos encontrarlas en el siguiente enlace: <https://numpy.org/install/>

- **Matplotlib:** Es una biblioteca que permite visualizar datos, principalmente permite la visualización en dos dimensiones (Rajagopalan, 2021), que para fines de esta serie de notebooks es suficiente. Con código podemos modificar distintos parámetros como: títulos, etiquetas, escala, tamaño de la figura y formato del texto de las gráficas.

Las instrucciones de descarga e instalación se encuentran disponibles en: <https://matplotlib.org/stable/users/installing/index.html>

- **Scipy:** es una biblioteca para cómputo científico y cómputo matemático (Rajagopalan, 2021). Contiene una serie de algoritmos de distintas disciplinas entre las que rescataremos cálculo, matrices y análisis de señales. Contiene distintos submódulos.

Las instrucciones para instalarlas las obtenemos en el siguiente enlace: <https://scipy.org/install/>

```
[1]: import numpy as np
import matplotlib.pyplot as plt
## %matplotlib inline
## %config InlineBackend.figure_formats = {'png', 'retina'}
import pandas as pd
import os.path as os
from scipy import*
```

```
[2]: carpeta = os.abspath('/Users/yann/Documents/Tesis/Datos/EEG') #localización del
#archivo en tu computadora
datos = pd.read_csv(carpeta +'H24_OC_OA.csv') #creación de un dataframe
#al que únicamente debes modificar el nombre del archivo con su extensión
datos #comando para presentar el dataframe
```

```
[2]:      EEG.AF3    EEG.F7    EEG.F3    EEG.FC5    EEG.T7    EEG.P7    EEG.O1    EEG.O2  \
0      4339.49   4521.03   4187.69   4627.69   4339.49   4112.31   4348.72   4252.31
1      4346.67   4527.18   4202.05   4633.85   4342.05   4122.05   4366.67   4267.69
2      4350.26   4540.00   4207.18   4643.08   4341.54   4122.05   4374.87   4271.28
3      4337.95   4530.77   4198.46   4638.46   4336.92   4118.97   4372.31   4258.97
4      4334.87   4519.49   4189.23   4629.23   4342.05   4118.97   4369.74   4245.64
...
23122  4414.87   4522.05   4201.54   4683.08   4384.62   4105.64   4361.54   4217.44
23123  4413.85   4524.10   4200.51   4685.64   4388.72   4106.15   4349.74   4196.92
23124  4416.41   4523.08   4204.62   4690.26   4391.28   4102.05   4337.44   4183.59
23125  4413.85   4520.51   4205.13   4687.69   4383.08   4094.36   4336.41   4183.59
23126  4409.74   4518.97   4201.03   4683.08   4377.95   4096.92   4352.31   4192.31

          EEG.P8    EEG.T8    EEG.FC6    EEG.F4    EEG.F8    EEG.AF4
0      4932.82   4447.69   4475.38   4738.46   4420.51   4598.46
1      4949.74   4465.64   4485.64   4749.74   4432.82   4611.28
2      4954.36   4462.56   4485.13   4747.18   4430.77   4612.31
3      4936.92   4441.03   4472.31   4734.87   4413.85   4598.46
4      4923.08   4436.41   4471.28   4731.79   4416.41   4596.41
...
23122  4892.82   4362.05   4493.85   4757.44   4426.67   4627.18
23123  4875.90   4346.67   4476.92   4749.74   4412.82   4614.36
23124  4875.90   4349.74   4477.95   4752.82   4412.31   4616.41
23125  4875.90   4352.31   4485.64   4753.33   4413.33   4617.95
23126  4872.82   4345.13   4479.49   4749.23   4412.82   4609.74
```

[23127 rows x 14 columns]

## 1.5 1.5 Observando los datos sin procesar

Observamos un resumen de los datos crudos que arroja el equipo emotiv EPOC (EMOTIV, 2016). Al abrir el archivo tenemos la señal de catorce electrodos que se colocaron a los participantes, en este caso tenemos la visualización de un sólo sujeto. Podemos observar que tenemos 23094 filas que corresponden al valor de voltaje registrado obtenido con una frecuencia de muestreo de 128 datos por segundo para tener aproximadamente 3 minutos de datos. Cada una de las catorce columnas nos da el nombre del electrodo y con el arreglo se puede observar la posición de cada electrodo.

Para propósitos de esta parte del material, vamos a trabajar en cómo se extrae el archivo y cómo graficar para distintos tiempos. En el notebook 2 veremos que es importante realizar un proceso de filtrado para dar sentido fisiológico a los datos.

Corrobora el tiempo de adquisición del protocolo con el siguiente ejercicio. \* Obten el número de filas del dataframe utilizando una función len \* Divídalo por la frecuencia de muestreo \* Finalmente almacénalo en una variable llamada “t\_adq” \* ¿En qué unidades estará tu resultado?

Modifica el código presentado en la celda para obtener tu resultado

```
[3]: #Ejercicio
freqm= __
```

```
t_adq= --
print('El tiempo de adquisición fue de '+ str(t_adq) + ' segundos')
```

El tiempo de adquisición fue de segundos

[4]: #Solución

```
freqm= 128
t_adq= len(datos)/freqm
print('El tiempo de adquisición fue de '+ str(t_adq) + ' segundos')
```

El tiempo de adquisición fue de 180.6796875 segundos


## 1.6 1.6 Primer abordaje para observar los datos en el dominio del tiempo.

A continuación se presenta un código con el que podemos visualizar los valores de cada electrodo en el rango de 0 a 180 segundos.


[5]:

```
fm=128 #frecuencia de muestreo
ti=0 #tiempo de inicio, debe ser número entero
tf=180 #tiempo final, debe ser número entero
pt=(tf-ti)*fm#numero de puntos
t1=ti*fm #nos ayuda a dar la posición de la fila para el tiempo inicial
t2=tf*fm #nos ayuda a dar la posición de la fila para el tiempo final
nombres=list(datos) #almacena los nombres de los encabezados en una lista
t=np.linspace(ti,tf,pt)


for i in range (0,14):
    plt.figure(figsize=(12,3))
    plt.plot(t,np.array(datos)[t1:t2,i])
    plt.title(nombres[i]) #itera sobre el nombre de las columnas para dar título a los gráficos
    plt.xlabel('tiempo'+ ' [s]')
    plt.show()
```




EEG.F7




EEG.F3




EEG.FC5




EEG.T7




EEG.P7




EEG.O1




EEG.O2







EEG.P8



EEG.T8







Si quisieras obtener una vista en un rango diferente de tiempo, por ejemplo para ver por separado los intervalos de tiempo del protocolo tendrías que modificar algunas variables en el código. Inténtalo en una celda de código. \* ¿Qué variables se modificaron? Esta forma de visualizar los datos no nos permite apreciar algunas características de la señal y tampoco podemos ver la escala de 30 segundos que es relevante para el protocolo. \* ¿Por qué esta forma de visualizar es poco práctica? \* ¿Cómo podrías mejorarlala?

#### **Nota técnica sobre los valores exportados por EmotivPRO**

Los archivos CSV generados por el sistema *Emotiv EPOC+* contienen valores expresados en microvoltios, pero estos provienen de la conversión directa de un registro de **14 bits sin signo**.

El fabricante especifica que la señal presenta un **nivel DC aproximado de 4100 μV** debido al punto de referencia interno del convertidor analógico-digital y a una **deriva lenta (DC drift)** asociada a la impedancia de los electrodos y la electrónica del amplificador.

Este desplazamiento no se corrige en el firmware, por lo que el usuario debe aplicar un **filtro pasaaltas** para eliminar el componente DC.

Emotiv recomienda una frecuencia de corte de **al menos 0.16 Hz** para compensar esta deriva (Emotiv, 2024).

En consecuencia, los valores observados en el rango de miles de microvoltios no representan actividad cortical real, sino el **offset de referencia** propio del sistema.

## **1.7 1.7 Mejorando la visualización**

Una solución es visualizar en un sólo panel que contenga las señales de los 14 electrodos, además de modificar el tamaño de las figuras. Nuestras herramientas serán:

- \* Convertir las columnas del dataframe en arreglos.
- \* Almacenar los nombres de los electrodos en una lista para iterar sobre ella y usar los nombres para etiquetar el eje Y en vez de usar los nombres como título superior de cada gráfica.
- \* Hacer un panel con los 14 electrodos haciendo subplots valiéndonos de un ciclo for.

Además recordamos que durante la tarea del protocolo experimental se quiere observar cambios de actividad en intervalos de 30 segundos, el nuevo código incluye una escala de 30 segundos para conseguir este fin.


```
[6]: ##Abierto
fm=128 #frecuencia de muestreo
ti_c=105 #tiempo de inicio, debe ser número entero
tf_c=120 #tiempo final, debe ser número entero
pt_c=(tf_c-ti_c)*fm#numero de puntos
t1_c=ti_c*fm #nos ayuda a dar la posición de la fila para el tiempo inicial
t2_c=tf_c*fm #nos ayuda a dar la posición de la fila para el tiempo final
nombres=list(datos) #almacena los nombres de los encabezados en una lista
t_c=np.linspace(ti_c,tf_c,pt_c)
escala_c=1
rg_c=int(tf_c/escala_c)

# Crear una sola figura con todos los subplots
plt.figure(figsize=(15,12))

for i in range (0,14):
    plt.subplot(14,1,i+1) #(filas, columnas, i)
    plt.xticks([escala_c*j for j in range(rg_c+1)])
    plt.plot(t_c,np.array(datos)[t1_c:t2_c,i]) #t tiempo, i posición
    plt.ylabel(nombres[i])#itera sobre el nombre de las columnas para dar título a los gráficos

# Agregar etiqueta de tiempo solo en el último subplot
if i == 13: # último subplot (índice 13 para 14 canales)
    plt.xlabel('Tiempo [s]')









plt.tight_layout() # Ajustar espaciado entre subplots
plt.show()
```









```
[7]: ##Cerrado
fm=128 #frecuencia de muestreo
ti_a=120 #tiempo de inicio, debe ser número entero
tf_a=135 #tiempo final, debe ser número entero
pt_a=(tf_a-ti_a)*fm#numero de puntos
t1_a=ti_a*fm #nos ayuda a dar la posición de la fila para el tiempo inicial
t2_a=tf_a*fm #nos ayuda a dar la posición de la fila para el tiempo final
nombres=list(datos) #almacena los nombres de los encabezados en una lista
t_a=np.linspace(ti_a,tf_a,pt_a)
escala_a=1
rg_a=int(tf_a/escala_a)

for i in range (0,14):
    plt.figure(figsize=(15,12))
    plt.subplot(14,1,i+1) #(filas, columnas, i)
    plt.xticks([escala_a*j for j in range(rg_a+1)])
    plt.plot(t_a,np.array(datos)[t1_a:t2_a,i]) #t tiempo, i posición
    plt.ylabel(nombres[i])#itera sobre el nombre de las columnas para dar título a los gráficos
```

```
plt.show()
```






- ¿Cómo mejoró esta visualización con respecto a la anterior?
- ¿En qué parte del código se cambió el tamaño?
- ¿Puedes identificar en qué partes del código se incluye la modificación de la escala?
- ¿Cómo modificarías el código para observar los primeros 5 canales? (Recuerda que Python comienza contando en 0)
- ¿Qué necesitas hacer si quieres visualizar algún canal en específico?
- ¿Qué columnas de datos corresponden a los occipitales? ¿Cómo los graficarías?

[8]: #Graficando un solo canal

```
plt.figure(figsize=(10,4)) #tamaño de la figura
plt.ylabel(nombres[6])
plt.title('Actividad de 105 a 120 segundos en ojos abiertos')
plt.plot(t_c,np.array(datos)[t1_c:t2_c,6])
plt.ylim(4320,4420)
```

[8]: (4320.0, 4420.0)



Estas señales tienen ruido, artefactos etc. En el siguiente notebook veremos cómo filtrar. Aquí tenemos que corregir la fluctuación. La visualización se vuelve difícil cuando no se filtran bien los datos.

## 2 1.8 Ejercicios exploratorios — Naturaleza y visualización de la señal EEG

En esta sección se propone un conjunto de ejercicios diseñados para **explorar los fundamentos empíricos del registro EEG**, sin aplicar procesamiento digital avanzado.

El propósito es **comprender la naturaleza física y digital** de la señal, observar su comportamiento en el tiempo y **reflexionar sobre los fenómenos básicos**: muestreo, amplitud, offset y variabilidad.

### 2.0.1 Instrucciones generales

- Trabaja directamente con los datos reales del EEG (`/Datos/EEG/H24_OC_OA.csv`).
- En este cuaderno, el canal **O1 corresponde al índice 6** (acceso por posición de columna).
- Ejecuta cada bloque y responde las preguntas en celdas Markdown debajo de cada ejercicio.
- No se busca obtener valores exactos, sino desarrollar intuición sobre cómo “respira” la señal cerebral.
- Puedes repetir los ejercicios con otros canales o archivos de sujetos diferentes para comparar su morfología.

### 2.1 Ejercicio 1 — Visualización básica del EEG


#### Objetivo:

Observar la morfología general de la señal EEG, reconocer su estructura temporal y familiarizarse con la escala de amplitud típica en microvoltios.

### Indicaciones:

1. Ejecuta la celda correspondiente y observa la señal completa del canal O1.
2. Cambia de canal (por ejemplo, Fp1, F3, C4, etc.) modificando el índice en el código.
3. Describe en tus palabras qué representa físicamente una **muestra individual** del EEG.
4. Registra en una celda Markdown tus observaciones sobre la variabilidad y el “ruido” presentes en el registro.

```
[9]: # --- Ejercicio 1: Visualización básica del EEG ---  
import pandas as pd  
import numpy as np  
import matplotlib.pyplot as plt  
  
# --- Parámetros de adquisición ---  
fs = 128          # Frecuencia de muestreo [Hz]  
canal_idx = 6      # O1 corresponde al índice 6 (acceso por posición)  
ruta = '/Users/yann/Documents/Tesis/Datos/EEG/H24_OC_OA.csv'  
  
# --- Carga de datos ---  
datos = pd.read_csv(ruta)  
ncols = datos.shape[1]  
assert canal_idx < ncols, f'El índice {canal_idx} excede el número de columnas ↵({ncols}).'  
  
x = datos.iloc[:, canal_idx].astype(float).to_numpy()  
t = np.arange(len(x)) / fs  
  
# --- Visualización de la señal completa ---  
plt.figure(figsize=(12,4))  
plt.plot(t, x, lw=0.9)  
plt.title('Señal EEG - Canal 01 (índice 6)', fontsize=13, fontweight='bold')  
plt.xlabel('Tiempo [s]')  
plt.ylabel('Amplitud [µV]')  
plt.grid(alpha=0.3)  
plt.tight_layout()  
plt.show()
```



## 2.2 Ejercicio 2 — Escala temporal y percepción visual

### Objetivo:

Explorar cómo la duración del segmento observado modifica la percepción de la señal y su nivel de detalle visible.

### Indicaciones:

1. Compara el segmento corto (~4 s) con el largo (~40 s).
2. Analiza qué detalles se pierden al aumentar la ventana temporal.
3. Explica por qué es útil analizar el EEG tanto en escalas cortas (milisegundos) como largas (decenas de segundos).
4. Anota tus conclusiones sobre cómo el “contexto temporal” cambia la interpretación visual del EEG.

```
[10]: # --- Ejercicio 2: Escala temporal y percepción visual ---
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

# --- Carga rápida de datos ---
fs = 128
canal_idx = 6
ruta = '/Users/yann/Documents/Tesis/Datos/EEG/H24_OC_0A.csv'

datos = pd.read_csv(ruta)
x = datos.iloc[:, canal_idx].astype(float).to_numpy()
t = np.arange(len(x)) / fs



# --- Segmento corto (~4 s) ---
plt.figure(figsize=(10,3))
plt.plot(t[:512], x[:512], lw=0.9)
```

```

plt.title('Segmento corto (~4 s) - O1 (índice 6)', fontsize=12)
plt.xlabel('Tiempo [s]')
plt.ylabel('Amplitud [µV]')
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()

# --- Segmento largo (~40 s) ---
plt.figure(figsize=(10,3))
plt.plot(t[:5120], x[:5120], lw=0.7, color='tab:gray')
plt.title('Segmento largo (~40 s) - O1 (índice 6)', fontsize=12)
plt.xlabel('Tiempo [s]')
plt.ylabel('Amplitud [µV]')
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()

```



## 2.3 Ejercicio 3 — Offset y referencia eléctrica

### Objetivo:

Identificar la presencia de un componente de corriente continua (offset) y comprender su significado instrumental.

### Indicaciones:

1. Ejecuta la celda para calcular y eliminar el offset promedio de la señal.
2. Observa el desplazamiento del eje base y su corrección.
3. Calcula el offset en un segmento corto (por ejemplo,  $x[1000:3000]$ ) y compáralo con el global.
4. Reflexiona sobre las posibles causas del desplazamiento constante (electrodos, impedancia, deriva térmica, etc.).
5. Describe por qué es importante establecer una **referencia eléctrica común** en las mediciones biológicas.

```
[11]: # --- Ejercicio 3: Offset y referencia eléctrica ---
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt


# --- Carga y configuración ---
fs = 128
canal_idx = 6
ruta = '/Users/yann/Documents/Tesis/Datos/EEG/H24_0C_0A.csv'

datos = pd.read_csv(ruta)
x = datos.iloc[:, canal_idx].astype(float).to_numpy()
t = np.arange(len(x)) / fs

# --- Cálculo del offset ---
offset = float(np.mean(x))
x_entrada = x - offset

# --- Gráfica ---
plt.figure(figsize=(12,4))
plt.plot(t, x_entrada, lw=0.8)
plt.axhline(0, color='gray', ls='--', lw=1)
plt.title('Señal EEG centrada respecto al eje de referencia - 01 (índice 6)',  
         fontsize=13)
plt.xlabel('Tiempo [s]')
plt.ylabel('Amplitud [µV]')
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()

print(f'Offset promedio (01, idx 6): {offset:.2f} µV')
```



Offset promedio (01, idx 6): 4369.68 µV

## 2.4 Ejercicio 4 — Variabilidad local de la señal

### Objetivo:

Analizar cómo cambia la morfología del EEG en distintos intervalos temporales de un mismo registro.

### Indicaciones:

1. Observa ambos fragmentos (segundos 5–10 y 60–65).
2. Describe las diferencias visibles en amplitud, densidad de oscilaciones o ritmo aparente.
3. Propón hipótesis sobre la causa de esas diferencias: ¿actividad muscular?, ¿movimientos oculares?, ¿cambios en la atención?
4. Reflexiona sobre cómo esta variabilidad refleja la naturaleza dinámica del cerebro incluso en reposo.

```
[12]: # --- Ejercicio 4: Variabilidad local de la señal ---
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

# --- Carga y centrado (automático si no existe) ---
fs = 128
canal_idx = 6
ruta = '/Users/yann/Documents/Tesis/Datos/EEG/H24_OC_0A.csv'

datos = pd.read_csv(ruta)
x = datos.iloc[:, canal_idx].astype(float).to_numpy()
t = np.arange(len(x)) / fs
offset = float(np.mean(x))
x_centrada = x - offset
```

```

# --- Definición de fragmentos ---
inicio1, fin1 = 5 * fs, 10 * fs
inicio2, fin2 = 60 * fs, 65 * fs


fig, ax = plt.subplots(2, 1, figsize=(10,5), sharex=True)

# --- Fragmento 1 ---
ax[0].plot(t[inicio1:fin1], x_entrada[inicio1:fin1], lw=0.9)
ax[0].set_title('Fragmento 1: segundos 5-10 (O1, índice 6)', fontsize=12)

# --- Fragmento 2 ---
ax[1].plot(t[inicio2:fin2], x_entrada[inicio2:fin2], lw=0.9, color='tab:gray')
ax[1].set_title('Fragmento 2: segundos 60-65 (O1, índice 6)', fontsize=12)

for a in ax:
    a.set_ylabel('Amplitud [µV]')
    a.grid(alpha=0.3)
plt.xlabel('Tiempo [s]')
plt.tight_layout()
plt.show()

```



## 2.5 Ejercicio 5 — Naturaleza digital y resolución temporal

### Objetivo:

Comprender que la señal EEG, aunque proviene de un fenómeno analógico, se representa de forma discreta mediante puntos de muestreo.

### Indicaciones:


1. Observa los puntos de muestreo individuales en la gráfica ( $\sim 1.6$  s de datos).
2. Calcula el intervalo de muestreo  $\Delta t = 1/f_s$  y razona su significado físico.
3. Explica en tus palabras la diferencia entre la señal continua original y la versión digital registrada.
4. Comenta por qué el muestreo a 128 Hz es suficiente para capturar la información relevante del EEG humano.

```
[13]: # --- Ejercicio 5: Naturaleza digital y resolución temporal ---
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

# --- Carga y centrado ---
fs = 128
canal_idx = 6
ruta = '/Users/yann/Documents/Tesis/Datos/EEG/H24_OC_0A.csv'

datos = pd.read_csv(ruta)
x = datos.iloc[:, canal_idx].astype(float).to_numpy()
t = np.arange(len(x)) / fs
offset = float(np.mean(x))
x_centered = x - offset

# --- Visualización de puntos de muestreo individuales ---
n_muestras = 200 # (~1.6 s)
plt.figure(figsize=(10,3))
plt.plot(t[:n_muestras], x_centered[:n_muestras], '-o', lw=1, ms=3)
plt.title(f'Muestreo digital del EEG (primeros {n_muestras} puntos) — O1 (índice 6)', fontsize=12)
plt.xlabel('Tiempo [s]')
plt.ylabel('Amplitud [µV]')
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()
```



## 2.6 1.9 Conexión con Notebooks siguientes

Los fundamentos establecidos en este notebook sientan las bases para los análisis posteriores:

### 2.6.1 1.9.1 Preparación para el Notebook 2 (Filtrado)

Las señales crudas visualizadas aquí revelan la necesidad crítica de procesamiento: - **Artefactos identificados:** Los artefactos observados en las visualizaciones justifican la implementación de filtros pasabandas específicos - **Ruido de línea base:** Las fluctuaciones DC observadas requieren corrección mediante filtros pasa-altas - **Optimización de parámetros:** Las características especiales anticipadas guiarán la selección de frecuencias de corte

Como mencionamos al observar las señales: “Estas señales tienen ruido, artefactos etc. En el siguiente notebook veremos cómo filtrar para dar sentido fisiológico a los datos.” El procesamiento adecuado de estas señales es fundamental para obtener resultados neurofisiológicamente interpretables y clínicamente relevantes.

## 2.7 1.10 Bibliografía

EMOTIV. (2016, 3 de febrero). EMOTIV EPOC+ 14-channel wireless EEG headset. <https://www.emotiv.com/epoc/>

Emotiv. (2024). Understanding sensor values in exported CSV data. Emotiv Knowledge Base. Recuperado el 19 de octubre de 2025, de <https://www.emotiv.com/tools/knowledge-base/emotivpro/understanding-sensor-values-in-exported-csv-data>

Hari, R., & Puce, A. (2017). *MEG-EEG primer*. Oxford University Press.

La Vaque, T. J. (1999). The history of EEG Hans Berger: Psychophysiologist. A historical vignette. *Journal of Neurotherapy*, 3(2), 1-9.

Matplotlib Development Team. (2023). Installation — matplotlib 3.7.2 documentation. <https://matplotlib.org/stable/users/installing/index.html>

NumPy Developers. (2023). Installing NumPy. <https://numpy.org/install/>

Olejniczak, P. (2006). Neurophysiologic basis of EEG. *Journal of Clinical Neurophysiology*, 23(3), 186-189.

pandas Development Team. (2023). Installation — pandas 2.0.3 documentation. [https://pandas.pydata.org/docs/getting\\_started/install.html](https://pandas.pydata.org/docs/getting_started/install.html)

Rajagopalan, G. (2021). *A Python data analyst's toolkit: Learn Python and Python-based libraries with applications in data analysis and statistics*. Packt Publishing.

Ramos-Argüelles, F., Morales, G., Egózcue, S., Pabón, R. M., & Alonso, M. T. (2009). Técnicas básicas de electroencefalografía: principios y aplicaciones clínicas. *Anales del Sistema Sanitario de Navarra*, 32(Supl. 3), 69-82.

Saptono, D., Wahyudi, B., & Irawan, B. (2016). Design of EEG signal acquisition system using Arduino MEGA1280 and EEGAnalyzer. En *MATEC Web of Conferences* (Vol. 75, p. 04003). EDP Sciences.

SciPy Developers. (2023). Installation. <https://scipy.org/install/>

Shoka, A., Dessouky, M., El-Sherbeny, A., & El-Sayed, A. (2019). Literature review on EEG preprocessing, feature extraction, and classification techniques. *IEEE Access*, 7, 168611-168633.

Vallat, R., & Walker, M. P. (2019). A universal, open-source, high-performance tool for automated sleep staging. *eLife*, 8, e70092.

[ ]: